C7-12 対照的デコーディングを用いた指示学習データの合成

*一瀬 達矢[1], Youmi Ma[1], 大井 聖也[1], 小池 隆斗[1], 岡崎 直観[1,2,3]
1. 東京科学大学, 2. 産業技術総合研究所, 3. 国立情報学研究所 大規模言語モデル研究開発センター

問題意識 教師モデルの応答をそのまま指示学習に利用することは必ずしも最適でないのでは？

提案手法 CoDIT：教師モデルが指示学習で獲得した能力に焦点を当てて応答を合成する手法

成果 構築したデータセットが高い学習効果を持つことを複数のモデルで確認

背景

LLMは指示学習によって指示に従う能力を獲得

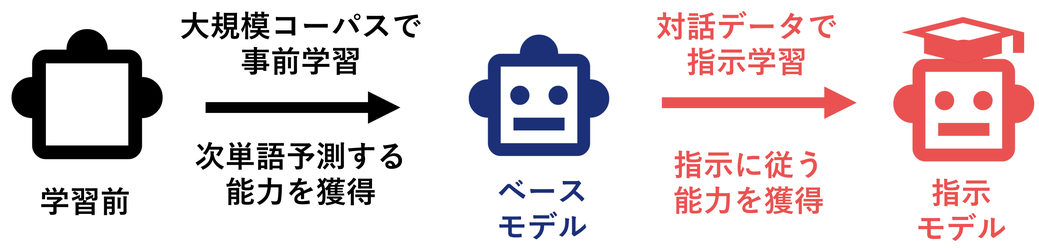

指示学習データ構築手法の現状

教師モデルの応答文をそのまま指示学習データに利用

- ➢ 教師モデルの応答文は事前学習と指示学習で得た能力を反映
- ➢ 指示学習で得た能力に焦点を当てて学習できないか

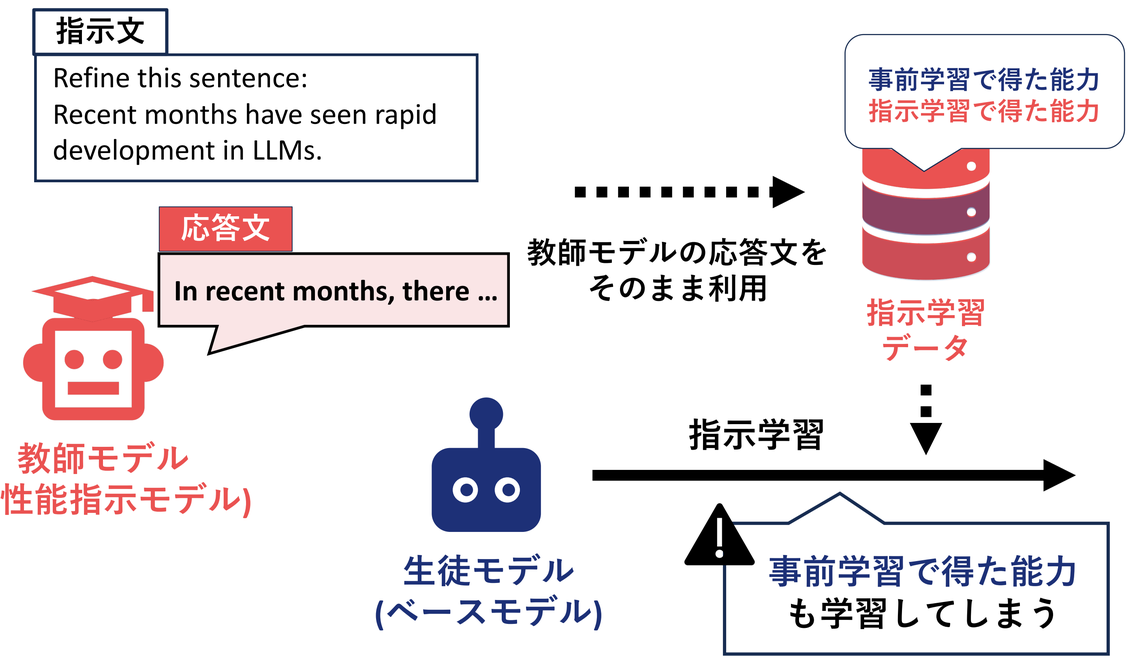

提案手法：CoDIT

指示モデルとベースモデルに対照的デコーディング[1]を適用し、対数確率差が最大になるようにトークンを生成

- ➢ 指示学習で得た能力に焦点を当てて学習できる

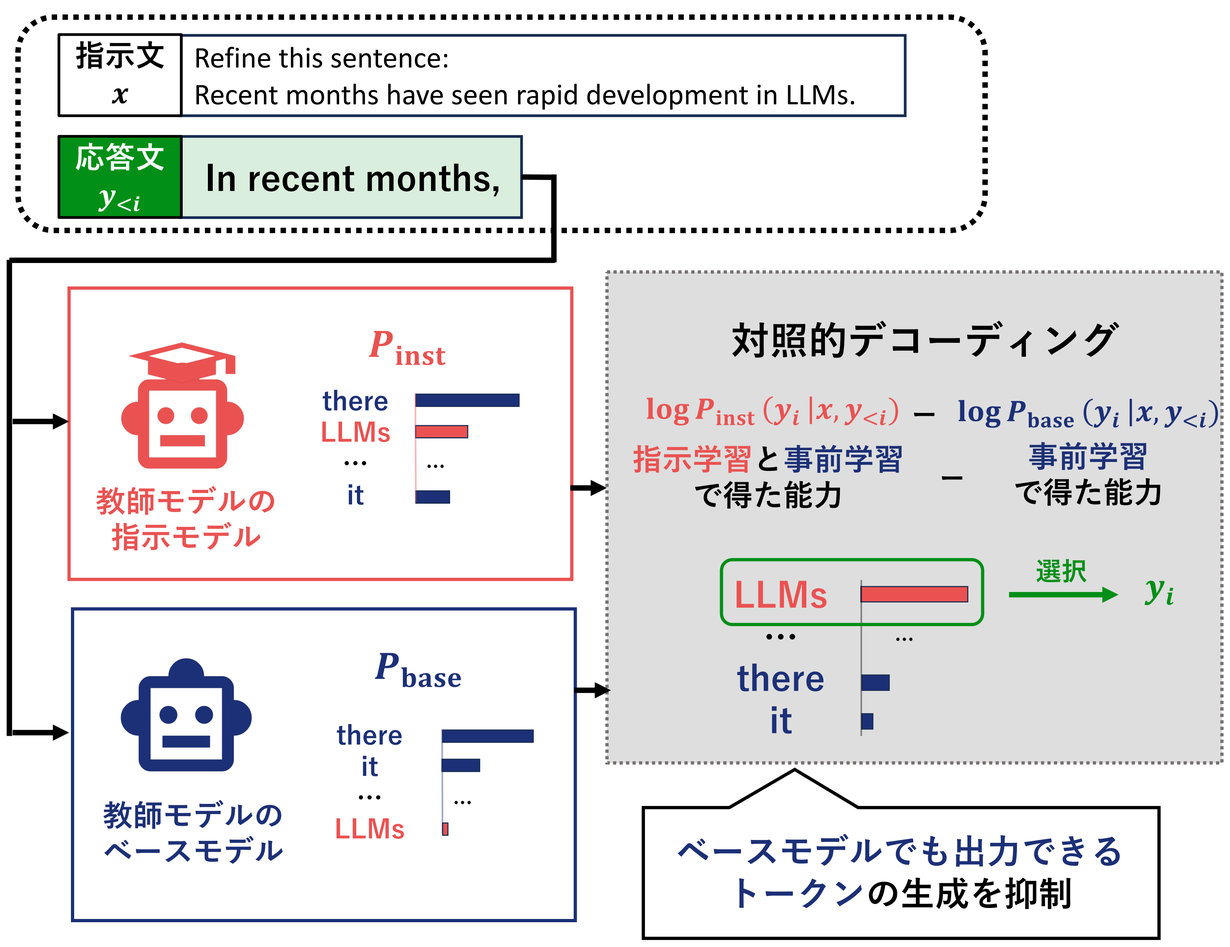

実験１：提案手法の有効性

- **指示文は固定：**LMSYS-Chat-1M [2]の英語指示文(約25万件)
- **応答文の合成手法を変えて比較**
  - **ベースライン**：教師モデルが生成した応答文
  - **提案手法**：教師モデルにCoDITを適用して生成した応答文
- **モデルによらない学習効果の検証：９つの組み合わせで実験**
  - **教師モデル：３モデル** (Qwen3-8B / Qwen3-30B-A3B / gemma-3-27b-it)
  - **生徒モデル：３モデル** (Llama-3.1-8B / Qwen3-8B-Base / gemma-3-4b-pt)

➢ 提案手法で構築したデータセットは指示学習効果が向上する傾向

WildBench [3] → 一貫して向上

教師モデル	Qwen3-8B			Qwen3-30B-A3B			Gemma-3-27B-IT		
生徒モデル	Llama	Qwen	Gemma	Llama	Qwen	Gemma	Llama	Qwen	Gemma
ベースライン	43.45	60.12	30.21	43.01	57.55	31.37	47.40	59.63	34.08
提案手法	**48.50**	**62.97**	**34.70**	**48.19**	**60.43**	**34.06**	**54.96**	**62.92**	**38.91**

AlpacaEval 2.0 [4] (Win Rate) → 一貫して向上

教師モデル	Qwen3-8B			Qwen3-30B-A3B			Gemma-3-27B-IT		
生徒モデル	Llama	Qwen	Gemma	Llama	Qwen	Gemma	Llama	Qwen	Gemma
ベースライン	52.55	64.76	40.42	51.78	59.47	40.36	69.51	71.67	55.12
提案手法	**58.73**	**69.45**	**47.18**	**56.76**	**63.79**	**43.46**	**75.95**	**76.26**	**59.80**

MT-Bench [5] → 同程度のスコア

教師モデル	Qwen3-8B			Qwen3-30B-A3B			Gemma-3-27B-IT		
生徒モデル	Llama	Qwen	Gemma	Llama	Qwen	Gemma	Llama	Qwen	Gemma
ベースライン	73.11	84.41	63.88	72.84	**84.39**	58.68	**74.44**	**83.64**	**67.88**
提案手法	**75.39**	**85.25**	**64.96**	**73.73**	84.18	**62.83**	74.33	83.13	67.14

実験２：先行研究との比較

- 先行研究で構築された指示学習データセットと比較

➢ 既存の指示学習データセットより高い学習効果

➢ 指示学習に有用な学習資源として公開した

データセット

データセット	件数	生徒：Llama-3.1-8B			生徒：Qwen3-8B-Base		
		Wild Bench	Alpaca Eval 2.0	MT-Bench	Wild Bench	Alpaca Eval 2.0	MT-Bench
WildChat [6]	442k	20.67	8.59	64.34	31.37	12.78	71.71
Llama-3.1 -LMSYS-Chat-1M-Synth [7]	454k	30.65	23.76	72.11	42.36	26.26	80.05
Gemma-2 -LMSYS-Chat-1M-Synth [7]	454k	35.67	27.44	69.51	46.26	31.10	74.56
CoDIT-Gemma3	250k	**54.96**	**75.95**	74.33	62.92	**76.26**	83.13
CoDIT-Qwen3-8B	250k	48.50	58.73	**75.39**	**62.97**	69.45	**85.25**
CoDIT-Qwen3-30B	250k	48.19	56.76	73.73	60.43	63.79	84.18

謝辞:本研究は JSPS 科研費 25H01137 の助成を受けたものです．本研究成果は，国立研究開発法人情報通信研究機構（NICT）の委託研究（22501）により得られたものです．本研究は，東京科学大学のスーパーコンピュータ TSUBAME4.0 を利用して実施しました．

[1]Contrastive Decoding: Open-ended Text Generation as Optimization. Xiang Lisa Li et al. 2022 [2]LMSYS-Chat-1M: A Large-Scale Real-World LLM Conversation Dataset. Lianmin Zheng et al. 2024 [3]WildBench: Benchmarking LLMs with Challenging Tasks from Real Users in the Wild. Bill Yuchen Lin et al. 2024 [4]AlpacaFarm: A Simulation Framework for Methods that Learn from Human Feedback. Yann Dubois et al. 2023 [5]Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. Lianmin Zheng et al. 2023 [6]WildChat: 1M ChatGPT Interaction Logs in the Wild. Wenting Zhao et al. 2024 [7]Building Instruction-Tuning Datasets from Human-Written Instructions with Open-Weight Large Language Models. Youmi Ma et al. 2025