対照的デコーディングを用いた指示学習データの合成

*一瀬 達矢[1]、馬 尤咪[1]、大井 聖也[1]、小池 隆斗[1]、岡崎 直観[1,2,3]
1. 東京科学大学、2. 産業技術総合研究所、
3. 国立情報学研究所 大規模言語モデル研究開発センター

概要

1. 目的：

- 多くの高性能な指示学習済みLLMが公開されているが、ほとんどの**指示学習データは非公開**
- ➢ **擬似的に合成**し、LLMの対話能力向上に寄与する**データの特徴を解明**

2. 提案手法：

- ベースモデルと指示モデルの間で**対照的デコーディングを適用し、指示学習データを合成**
- ➢ LLMが指示学習によって新たに獲得した能力のみを強調

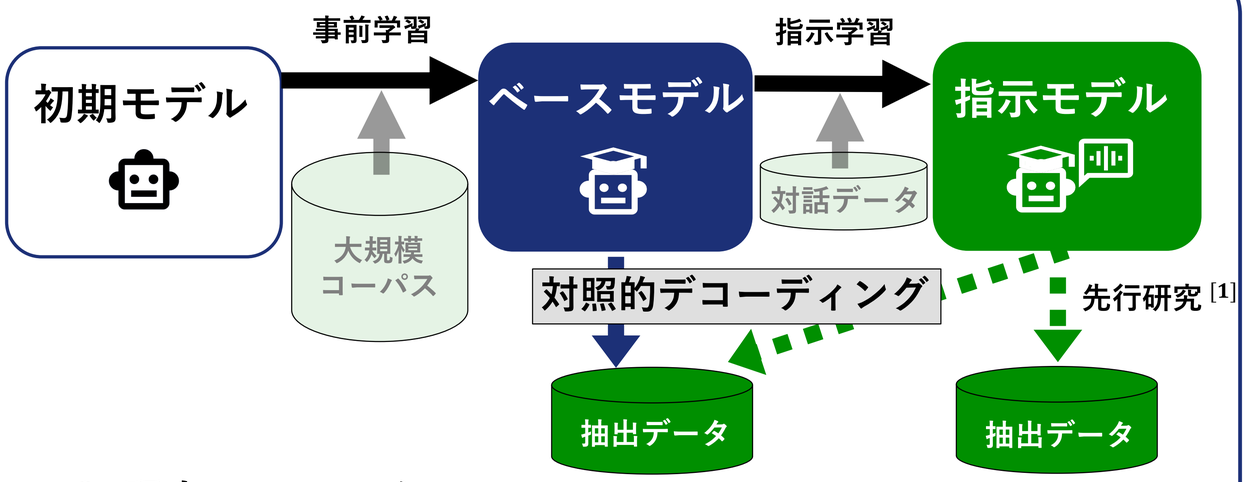

3. 現在のステータス：

- 先行研究[1]と比較して**対照的デコーディングを適用すると学習に使われたデータセットとの類似度が向上する**ことを学習データが分かっている実験的な環境で確認

① 先行研究

Magpie [1]

多くの指示モデルへの入力は①プレクエリ ②指示文 ③ポストクエリ

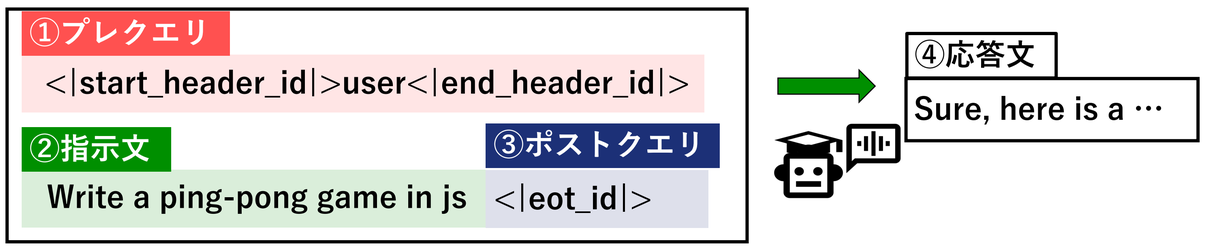

指示モデルに①プレクエリだけ入力するとモデルが②(指示文)を出力

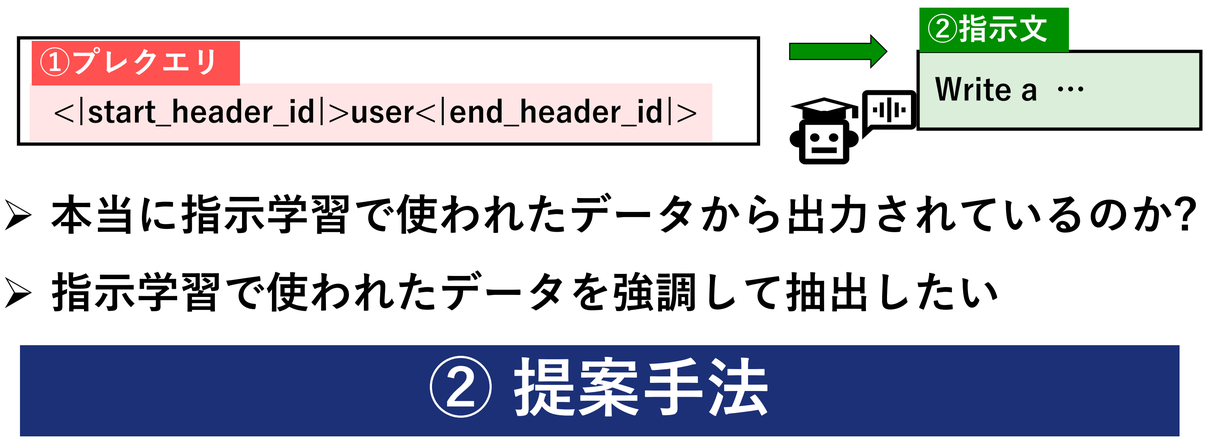

- ➢ **本当に指示学習で使われたデータから出力されているのか?**
- ➢ **指示学習で使われたデータを強調して抽出したい**

② 提案手法

対照的デコーディング[2]を用いた指示文の合成

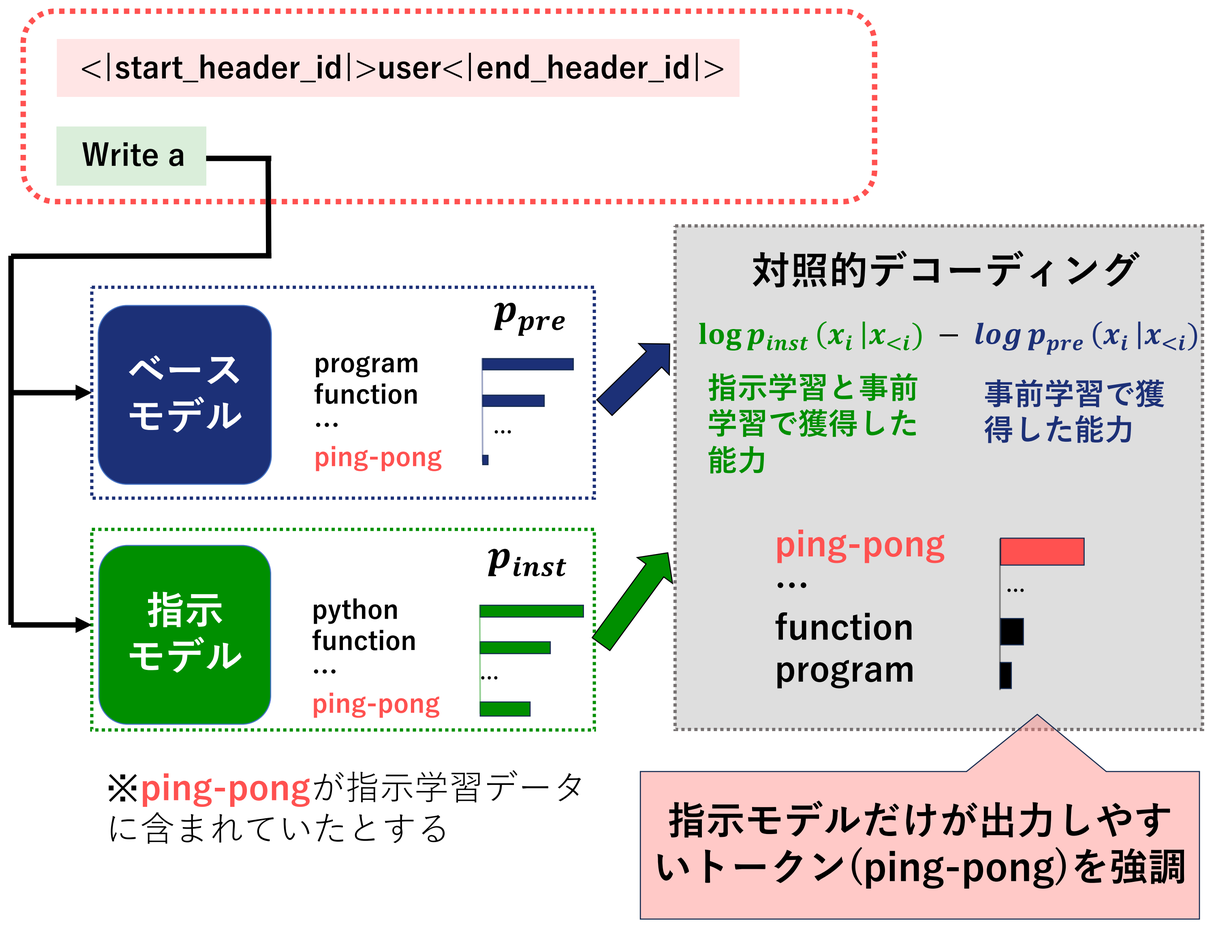

③ 実験

学習に使われたデータセットを抽出できているのか？

→学習データセットが分かっている状態で実験

- **学習データセット：Gemma-3-LMSYS-Chat-1M-Synth [3]**
- **指示モデル：** **meta-llama/Llama-3.1-8B [4]を学習データセット**で指示学習

	指示文	応答文
学習データセット(250,333件)	**人手**により作成	google/gemma-3-27b-it [5]
比較手法(250,333件)	**対照的デコーディングなし**で作成	
提案手法(250,333件)	**対照的デコーディング**により作成	

比較手法, 提案手法の両方について、指示文のフィルタリングと重複除去[6]を行いデータセットを作成した。

学習データセットと意味的に近いのか？

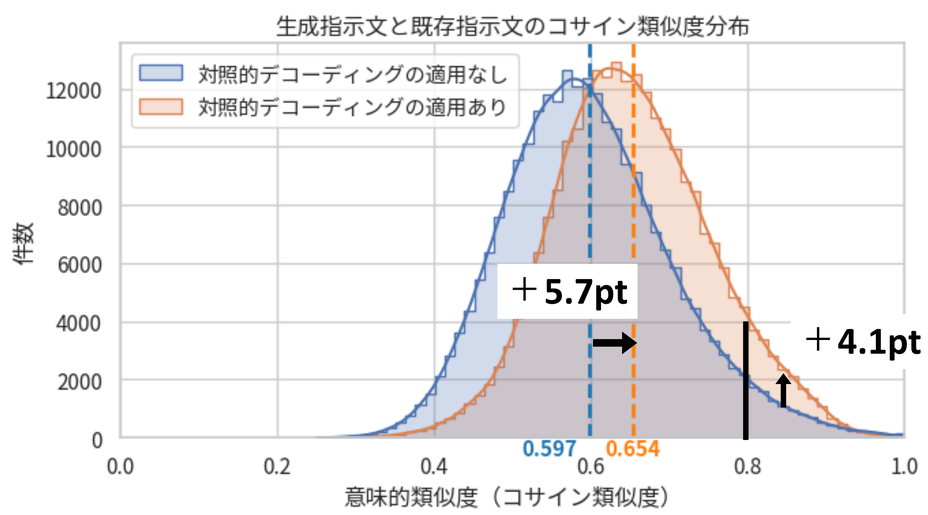

- ➢ **対照的デコーディングを適用することでより学習データセットに似た文が抽出できている**

学習データセットと学習効果は近いのか？

	MT-Bench [7]	Arena-Hard-v2.0 [8]		WildBench [9]	
	average	Hard Prompt	Creative Writing	WB-Elo	WB-Score
学習に使われたデータセット	0.724	**1.7**	20.8	**1153**	**7.55**
対照的デコーディングなしのデータセット	**0.725**	1.3	**22.1**	1149	7.52
対照的デコーディングありのデータセット	0.724	1.4	19.9	1149	7.48

- ➢ **学習効果は向上していない**
- ➢ **対照的デコーディングによって語彙が強調されて偏り、多様性を失ったのではないか**

謝辞: 本研究はJSPS科研費 25H01137の助成を受けたものです。

[1] Magpie: Alignment Data Synthesis from Scratch by Prompting Aligned LLMs with Nothing. Zhangchen Xu et al. 2024 [2] Contrastive Decoding: Open-ended Text Generation as Optimization. Xiang Lisa Li et al. 2022 [3] Building Instruction-Tuning Datasets from Human-Written Instructions with Open-Weight Large Language Models. Youmi Ma et al. 2025 [4] https://huggingface.co/meta-llama [5] https://huggingface.co/google/gemma-3-27b-it [6] Building a Large Japanese Web Corpus for Large Language Models. Naoaki Okazaki et al. 2024 [7] Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. Lianmin Zheng et al. 2023 [8] From Crowdsourced Data to High-Quality Benchmarks: Arena-Hard and BenchBuilder Pipeline. Li, Tianle et al. 2024 [9] WildBench: Benchmarking LLMs with Challenging Tasks from Real Users in the Wild. Bill Yuchen Lin et al. 2024